


Inteligencia Artificial

Ayudantía 6: Clustering

Profesores: Johan Fuentes y Víctor Reyes

Ayudantes: Diego Banda y Eduardo Escalona



Contacto

Sección 1

Ayudante Cátedra



diego.banda@mail.udp.cl



DarKclouds

Ayudante Corrector



vicente.leiva2@mail.udp.cl

Sección 2

Ayudante Cátedra



eduardo.escalona1@mail.udp.cl

Ayudante Corrector



tomas.diaz_c@mail.udp.cl

Clustering



Es una técnica de **Aprendizaje No Supervisado**

No conoce la
etiqueta
previamente

El clustering agrupa datos no etiquetados según patrones o similitudes entre los elementos.

Objetivo:

Los elementos dentro de un mismo grupo deben compartir características comunes. Los grupos deben ser lo suficientemente distintos entre sí.



K-MEANS

¿Qué es?

Es un algoritmo que consiste en agrupar los datos bajo K cluster iniciales, los cuales se moverán en base a la cercanía de los datos.



¿Cómo funciona?

- Colocar K puntos en el espacio de datos representado por los objetos a ser clasificados. Estos puntos se denominan centroides iniciales.
- Se asigna cada objeto (dato) al centroide más cercano .
- Una vez asignados todos los objetos a sus respectivos grupos, se recalcula la posición del centroide.
- Se repiten los pasos 2 y 3 hasta que los centroides no cambien de posición.

Ventajas/Desventajas

Ventajas:

- Fácil implementación
- Rápida convergencia
- Fácil interpretación

Desventajas:

- No asegura la mejor clasificación
- No considera outliers
- Depende mucho de la ubicación de los centroides

K-MEANS: ejemplo


Se tienen los puntos P_1 , P_2 , P_3 y P_4 , ejecute K-MEANS utilizando $K = 2$, el centroide inicial de cada cluster es C_1 y C_2 .

$$P_1 = (1, 1)$$

$$P_2 = (3, 1)$$

$$P_3 = (4, 3)$$

$$P_4 = (5, 4)$$



$$C_1 = (0, 0)$$


$$C_2 = (5, 0)$$

¿Qué pasa si tenemos $C_1 = (0, 0)$ y $C_2 = (500, 500)$?

Método del codo

¿Qué es?

Es una técnica visual que se usa en el aprendizaje no supervisado para encontrar el número "ideal" de grupos (o clústers) en un conjunto de datos. Su nombre viene de la forma del gráfico que produce (simula un brazo doblado).



¿Cómo funciona?

- Se ejecuta un algoritmo de clustering (como k-means) múltiples veces, con muchos valores de k (que es el parámetro a ajustar).
- Para cada k , se calcula una métrica de error (inercia o suma de los cuadrados en el clúster) para ver qué tan compactos son los grupos. Un error más bajo es mejor.
- Se crea el gráfico, donde el eje X corresponde a la cantidad de clústers (k), mientras que el eje Y refleja el valor del error calculado.

Ventajas/Desventajas

Ventajas:

- **Fácil de visualizar.**
- **Buen punto de partida.**
- **Basado en el rendimiento.**

Desventajas:

- **Puede ser subjetivo.**
- **Potencialmente costoso.**
- **Sensible a la distribución de los datos (grupos esféricos y similares en tamaño).**

MEAN-Shift

¿Qué es?

Este algoritmo se basa en la moda y densidad. Identifica clusters en los datos desplazando iterativamente cada punto hacia la región de mayor densidad de datos en su vecindad. Los parámetros son los siguientes:

- Función de cálculo de vecinos
- Kernel probabilístico

Movimiento a efectuar por el cluster:

¿Cómo funciona?

1. Itera **N** veces sobre cada punto hasta que converja (cada punto es un centroide inicialmente)
2. Encontrar conjuntos de vecinos
3. Comprobar si cumple con la condición de distancia
4. Comprobar si cumple el kernel

$$m(x) = \frac{\sum_{x_i \in N(x)} K(x, x_i) x_i}{\sum_{x_i \in N(x)} K(x, x_i)}$$

Ventajas/Desventajas

Ventajas

- **No requiere especificar K**

Desventajas:


- **Alto costo computacional**

La función K (kernel) puede variar, pero la más usada es el Kernel Gaussiano:

$$K(x, x_i) = e^{-\frac{\|x - x_i\|^2}{2\sigma^2}}$$

MEAN-Shift: ejemplo

Ejecutar MEAN-shift con un $K(x, x_i) = 1$ y bandwidth = 3.



DBSCAN

¿Qué es?

Este algoritmo se basa en la moda y densidad. Identifica clusters en los datos desplazando iterativamente cada punto hacia la región de mayor densidad de datos en su vecindad. Los parámetros son los siguientes:

- Función de cálculo de vecinos
- Kernel probabilístico

¿Cómo funciona?

1. Se recorre cada punto del conjunto de datos.
2. Si un punto tiene al menos **MinPts** vecinos dentro del radio ϵ , se inicia un nuevo cluster.
3. Los vecinos se incorporan recursivamente al grupo si cumplen la misma condición de densidad.
4. Los puntos que no pertenecen a ninguna región densa se clasifican como ruido o outliers.


Ventajas/Desventajas

Ventajas

- **Fácil implementación**
- **Rápida convergencia**
- **no requiere especificar k**
- **Detecta outliers**

Desventajas:

- **No asegura la mejor clasificación**
- **Sensible a la elección de ϵ , puede fallar en datos de densidad variable**




Tipos de nodos/puntos

-  **Núcleo:** $\Rightarrow$ MinPts de puntos conectados dentro de un radio ϵ
-  **Borde:** $<$ MinPts de puntos conectados dentro de un radio ϵ , pero son parte del vecindario de otro punto.
-  **Ruido:** outliers



DBSCAN: ejemplo

Ejecutar DBSCAN con $\text{eps} = 2$ y $\text{minPts} = 3$, debe identificar qué tipo de punto es cada uno.



AHC

¿Qué es?

Es un método de agrupación ascendente que comienza con cada punto de datos como un grupo separado y fusiona iterativamente los pares de grupos más cercanos hasta que todos los puntos de datos se encuentren en un único grupo grande. La jerarquía de estas fusiones se visualizan mediante un árbol invertido.

¿Cómo funciona?

1. Comienza con cada punto como su propio cluster
2. Itera mientras haya más de un cluster
3. Evalúa todas las distancias entre clusters de a pares
4. Registra las distancias entre clusters en una matriz
5. Busca la menor distancia entre clusters y luego los fusiona

Ventajas/Desventajas

Ventajas

- **No requiere especificar el número de clusters**
- **Útil para entender jerarquía**

Desventajas:

- **Alto costo computacional en conjuntos grandes**
- **No permite deshacer fusiones previas**
- **La elección de como se mide la distancia puede afectar al resultado final**

AHC: ejemplo

Dibuje el árbol resultante al ejecutar AHC en un plano de 1 dimensión, utilizando los siguientes puntos:

- A = 2
- B = 4
- C = 7
- D = 8
- E = 12
- F = 15
- G = 27

Método de la silueta

¿Qué es?

Es una técnica utilizada en aprendizaje no supervisado para evaluar qué tan bien están formados los clústeres.

Se basa en el **Silhouette Score**, un valor entre -1 y 1 que mide qué tan parecido es un dato a su propio grupo en comparación con otros grupos.

- Cerca de 1 → clústeres bien definidos.
- Cerca de 0 → grupos cercanos o solapados.
- Cerca de -1 → posible mala clasificación.

¿Cómo funciona?

Se ejecuta un algoritmo de clustering (como K-Means) con distintos valores de k.

Para cada k, se calcula el Silhouette Score promedio de todos los datos.

Este score evalúa:

Qué tan compactos son los grupos.

Qué tan separados están entre sí.

Luego se genera un gráfico donde:

El eje **X** representa la **cantidad de clústeres**.

El eje **Y** representa **el Silhouette Score**.

El mejor valor de k suele ser el que obtiene el puntaje más alto.


Ventajas/Desventajas

Ventajas:

- Evalúa cohesión y separación de clústeres.
- Fácil de interpretar.
- Ayuda a detectar agrupamientos poco claros.

Desventajas:

- Más costoso computacionalmente.
- Puede verse afectado por la distribución de los datos.



Ejercicio 1

(20 puntos) Suponga que Mr.Brisket posee un dataset de la forma (x_1, x_2) :

$$A(1, 8), B(2, 1), C(3, 2), D(8, 8), E(9, 9), F(7, 3), G(1, 9).$$

Mr.Brisket aplica el algoritmo k-means al conjunto anterior, considerando para ello la distancia Chebyshev, definida por:

$$d(a, b) = \max_i (|a_i - b_i|)$$

en donde $a = (a_1, a_2, \dots, a_n)$ y $b = (b_1, b_2, \dots, b_n)$. Luego de hacer un cierto número de iteraciones llega a los siguientes X clusters: $C_1 = \{A, B, C\}$, $C_2 = \{G\}$, $C_3 = \{D, E, F\}$. A partir de este escenario, ejecute una iteración del algoritmo, y muestre cómo quedarían los nuevos clusters.

Ejercicio 2

(15 puntos) Considere los siguientes puntos en el plano (x_1, x_2) :

$A(0, 0)$, $B(0, 1)$, $C(1, 0)$, $D(1, 1)$, $E(5, 5)$, $F(5, 6)$, $G(6, 5)$, $H(3, 3)$, $I(2, 2)$, $J(6, 6)$.

Use DBSCAN, considerando la distancia Euclidiana, con parámetros $\varepsilon=1.5$ y $\text{MinPts} = 4$ (conteo *incluye* al propio punto) para determinar los clústeres resultantes y los puntos outliers.

**Muchas gracias
por su atención!!**

